## Corso di Architettura degli Elaboratori e Laboratorio (M-Z)

# Rappresentazione binaria di dati complessi

#### Nino Cauli



Dipartimento di Matematica e Informatica

# Sistemi di numerazione posizionali



#### Un sistema di numerazione e definito da:

- Un intero B detto BASE
- Un insieme di B simboli  $S_B = \{s_0, ..., s_{B-1}\}$ , ognuno dei quali rappresenta le quantità 0,1,2,...,B-1

Un numero a n cifre  $p_{(n-1)}p_{(n-2)}...p_1p_0$  con  $p_{(i)} \in S_B$  e i=0,...,n-1 può essere rappresentato come **SOMMA DI POTENZE DELLA BASE**:

$$\sum_{i=0}^{n-1} (p_{(i)} \cdot B^i)$$

## Numeri interi naturali in binario



$$P = p_{(n-1)}p_{(n-2)}...p_1p_0$$
,  $p_{(i)} \in \{0,1\}$  e  $i=0,...,n-1$ 

$$\sum_{i=0}^{n-1} p_{(i)} \cdot 2^i$$

Numero di valori rappresentabili =  $[0, 2^n)$ 

## Numeri con segno



## Segno:

• Bit più a sinistra = BIT DI SEGNO

#### Valore assoluto:

- SEGNO E VALORE ASSOLUTO
- COMPLEMENTO A UNO
- COMPLEMENTO A DUE

## Somma complemento a due



**ADDIZIONE**: come quella binaria naturale, ma trascurando il riporto in uscita

**SOTTRAZIONE**: addizione con il complemento a due del sottraendo

Figura 1.6 (parte) - Operazioni di addizione e sottrazione in complemento a due

# Trabocco (overflow)



Il risultato di addizione e sottrazione in complemento a 2 è corretto se è **COMPRESO** nell'intervallo:

$$[-2^{n-1}, 2^{n-1})$$

In caso contrario avviene un evento di TRABOCCO

Il TRABOCCO può avvenire solo se:

- 1) I due addendi sono CONCORDI IN SEGNO
- 2) Il **BIT DI SEGNO** della somma degli addendi è **DIVERSO** da quello degli addendi

## Estensione e riduzione del segno



Spesso si presenta la necessità di aumentare o diminuire il numero di bit usati per codificare un numero

Regole molto semplici:

- ESTENSIONE DEL SEGNO: si replica a sinistra il bit del segno tante volte quanto occorre
- RIDUZIONE DEL SEGNO: si rimuove il bit più a sinistra tante volte quante occorre, purché il bit successivo abbia ugual valore

### Numeri frazionari



## Come rappresentare i numeri frazionari in binario?

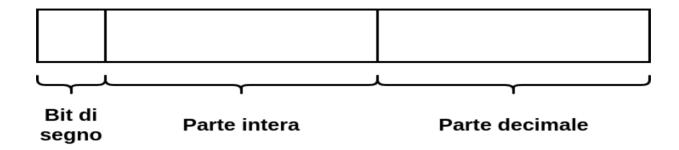
## **Idea semplice:**

- Un bit di segno
- Una porzione di bit fissa per la parte intera
- Una porzione di bit fissa per la parte decimale

Chiamiamo questa rappresentazione A VIRGOLA FISSA (FIXED POINT)

# Numeri a virgola fissa (fixed point)





#### Solo bit di segno e parte intera:

Valori rappresentabili: da -2<sup>n-1</sup> a 2<sup>n-1</sup> – 1

Risoluzione: 1

#### Solo bit di segno e parte decimale:

Valori rappresentabili: da -1 a 1 - 2<sup>-(n-1)</sup>

Risoluzione: 2-(n-1)

## Intervallo non sufficiente per calcoli scientifici.

# Numeri virgola mobile (floating point)



Per aumentare intervallo e risoluzione di valori rappresentabili si potrebbe spostare la posizione della virgola dinamicamente (VIRGOLA MOBILE)

Notazione scientifica decimale, **FORMA NORMALE**:

$$6,0247 \times 10^2 = 602,47$$

$$3,7291 \times 10^{-2} = 0,037291$$

In generale vale per ogni base:

$$1,0011 \times 2^2 = 100,11$$

$$4,2131 \times 5^{-2} = 0,042131$$

## Numeri frazionari



Un numero binario in virgola mobile può quindi essere rappresentato:

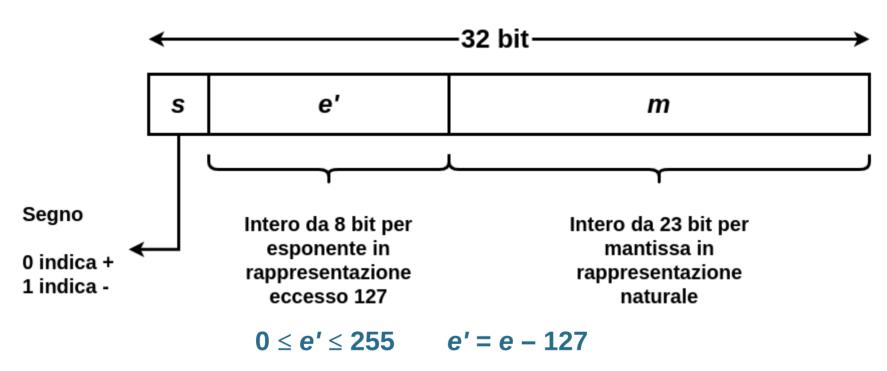
- Un **SEGNO** s per il numero
- La MANTISSA m (bit significativi escluso il bit più significativo)
- Un **ESPONENTE** *e* con segno in base 2

Valore rappresentato =  $\pm 1$ ,  $m \times 2^e$ 

## Formato precisione singola (32 bit)



#### Standard IEEE 754 numeri 32 bit



Valori speciali: e' = 0, e' = 255

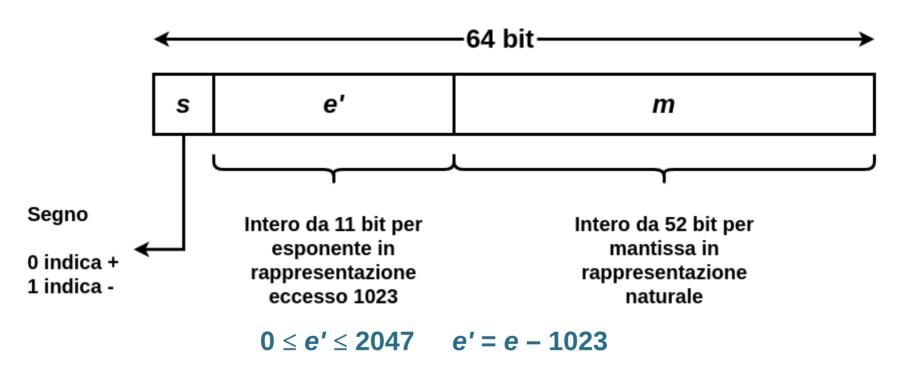
Intervallo esponente:  $-126 \le e \le 127$ 

Fattore di scala nell'intervallo: [2<sup>-126</sup>, 2<sup>127</sup>]

## Formato precisione doppia (64 bit)



#### Standard IEEE 754 numeri 64 bit



Valori speciali: e' = 0, e' = 2047

Intervallo esponente:  $-1022 \le e \le 1023$ 

Fattore di scala nell'intervallo: [2<sup>-1022</sup>, 2<sup>1023</sup>]

# Valori speciali



## Alcuni valori dell'esponente sono speciali:

- e' = 0, m = 0 rappresenta lo 0 esatto
- e' = 255(2047), m = 0 rappresenta l'infinito  $\infty$
- e' = 0,  $m \neq 0$  rappresenta la forma non normale:  $\pm 0$ ,  $m \times 2^{-126(-1022)}$
- e' = 255(2047),  $m \neq 0$  rappresenta Not a Number NaN

## Rappresentazione dei caratteri



#### Come rappresentare caratteri tramite una sequenza di *n* bit?

Associamo un carattere ad ogni possibile valore binario rappresentabile

### Quanti caratteri siamo in grado di rappresentare con *n* bit?

- Una sequenza di *n* bit può rappresentare 2<sup>n</sup> permutazioni di 0 e 1
- Si può rappresentare un alfabeto di **2**<sup>n</sup> **simboli**

## Vediamo gli standard più usati

## **Codice ASCII**



- Codice ASCII (American Standard Code for Information Interchange)
- Rappresenta lettere, cifre decimali, punteggiatura e caratteri speciali
- Definito su 7 bit → alfabeto di 2<sup>7</sup> =
  128 elementi
- Lettere e numeri con codici in ordine crescente

	Bit 654							
Bit 3210	000	001	010	011	100	101	110	111
0000	NUL	DLE	SPACE	0	@	P	4	р
0001	SOH	DC1	!	1	A	Q	a	q
0010	STX	DC2	"	2	В	R	b	r
0011	ETX	DC3	#	3	C	S	С	s
0100	EOT	DC4	\$	4	D	T	d	t
0101	ENQ	NAK	%	5	E	U	e	u
0110	ACK	SYN	&	6	F	V	$\mathbf{f}$	$\mathbf{v}$
0111	BEL	ETB	,	7	G	W	g	w
1000	BS	CAN	(	8	Н	X	h	x
1001	HT	EM	)	9	I	Y	i	У
1010	LF	SUB	*	:	J	Z	j	z
1011	VT	ESC	+	;	K	]	k	{
1100	FF	FS	,	<	L	/	1	
1101	CR	GS	_	=	M	]	m	}
1110	SO	RS		>	N	^	n	-
1111	SI	US	/	?	O	_	0	DEI

# Standard per alfabeti con più simboli



# Necessità di codici più ricchi per gestire le diverse lingue con caratteri speciali, accenti, etc.

#### Standard internazionali:

- Famiglia ISO 8859-x: estendono il codice ASCII usando 8 bit (doppio dei simboli)
- ISO/IEC 10646 (UCS): rappresentazione universale di caratteri che estende su più byte la ISO 8859
- Standard di codifica basati su UCS: come ad esempio UNICODE e UTF-8

## Codici di controllo e correzione di errore



# L'informazione binaria codificata potrebbe essere affetta da errori

#### Gli errori possono essere causati da:

- Disturbi nei canali di trasmissione
- Alterazione accidentale o dolosa nei dispositivi di memorizzazione

## Come si possono individuare e possibilmente correggere gli errori?

• Aggiungendo uno o più bit di controllo alla sequenza originale

# Bit di parità



Si aggiunge un bit di controllo (BIT DI PARITÀ) alla sequenza binaria originaria:

- 0 se numero PARI di 1 nella sequenza originaria
- 1 se numero **DISPARI** di 1 nella sequenza originaria

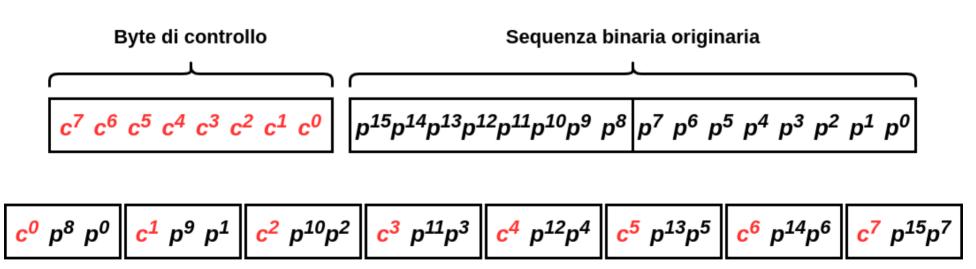
Se il numero di 1 nella **sequenza binaria estesa** con il bit di parità è **DISPARI** sono presenti errori

Rivela solo errori su di 1 bit e non può correggere gli errori rilevati

# Byte di controllo



- Estensione dell'idea di bit di controllo per sequenze di più byte
- 1 byte usato come informazione di controllo
- Ogni bit del byte controllo usato per la parità di sequenze non contigue di bit a distanza 8



Rivela più errori su in uno stesso byte

# Somma di controllo, CRC



Checksum: Estensione con sequenze di controllo più lunghe di un byte

- Algoritmi di controllo semplici meno robusti:
  - Somma dei bit
  - Parità di sotto-sequenze
- CRC (codice a ridondanza ciclica):
  - Algoritmi di controllo basati su algebra dei polinomi
  - Permettono di rilevare errori su lunghe sequenze di bit contigui

## Codici di correzione di errore



Codici di controllo con informazione necessaria per **correggere** fino a *k* errori sui bit

Si può usare il concetto di DISTANZA DI HAMMING

#### Distanza di Hamming:

- Di due sequenze: numero di bit diversi in posizioni corrispondenti
- Di un insieme di sequenze: la distanza di Hamming minima di coppie di sequenze distinte nell'insieme

# Proprietà distanza di Hamming



Un **codice** *c* a *n* bit che può rappresentare un **alfabeto** A di al più 2<sup>n</sup> simboli è una funzione iniettiva:

$$c: a \to \{0, 1\}^n$$

**Distanza di Hamming di un codice** = distanza di Hamming della sua immagine

#### Un codice con:

- Distanza di Hamming h può rivelare fino a h 1 errori
- Distanza di Hamming h = 2k + 1 può correggere fino a k errori

## Esempio distanza di Hamming



X	4 bit	7 bit	h <sub>0100011</sub>
0	0000	00 0 0 000	3
1	0001	11 0 1 001	3
2	0010	01 0 1 010	2
3	0011	10 0 0 011	2
4	0100	10 0 1 100	6
5	0101	01 0 0 101	2
6	0110	11 0 0 110	3
7	0111	00 0 1 111	3
8	1000	11 1 0 000	4
9	1001	00 1 1 001	4
Α	1010	10 1 1 010	5
В	1011	01 1 0 011	1
С	1100	01 1 1 100	5
D	1101	10 1 0 101	5
Е	1110	00 1 0 110	4
F	1111	11 1 1 111	4

Tabella A1.1 - Esempio di correzione di errore

## Rappresentazione di informazione multimediale



Informazione multimediale è originariamente ANALOGICA

- AUDIO: andamento pressione acustica nel tempo
- IMMAGINI: distribuzione di valori continui di luminanza in uno spazio bidimensionale
- VIDEO: sequenza temporale di immagini

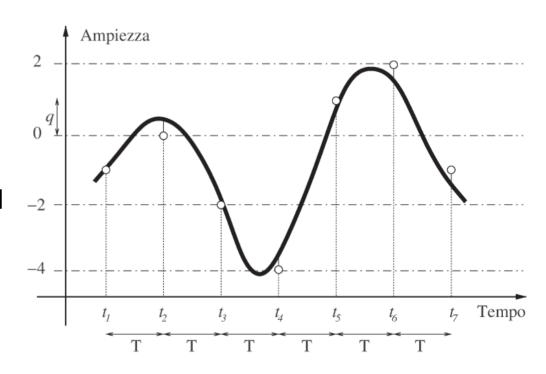
Per essere rappresentata in biniario l'informazione multimediale deve essere DISCRETIZZATA

# Discretizzazione nel tempo



### La discretizzazione nel dominio del segnale (tempo) è chiamata CAMPIONAMENTO

- Segnale campionato a intervalli di tempo regolari
- Intervallo di tempo detto PERIODO
  T
- FREQUENZA di campionamento è il reciproco del periodo
- La frequenza è espressa in hertz (Hz), campionamenti al secondo

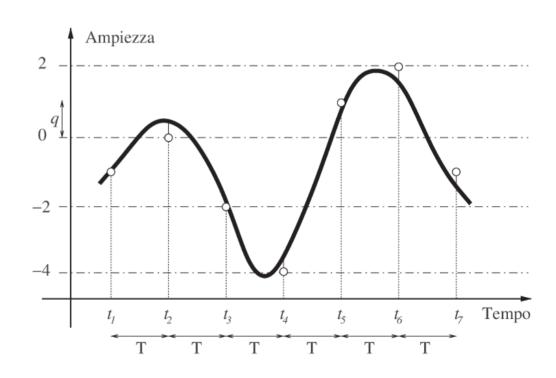


# Discretizzazione nell'intensità del segnale



# La discretizzazione nel codominio del segnale (intensità) è chiamata **QUANTIZZAZIONE**

- Unità di quantizzazione è detta q
- I valori analogici del segnale vengono approssimati al valore multiplo di q più vicino
- Valori quantizzati rappresentati dai coefficienti di q



## Rappresentazione Audio



- Intervallo fisiologico di frequenze udibili dall'uomo: da circa 20 Hz a 20 kHz
- Per rappresentare un segnale analogico di frequenza massima  $f_m$ , un segnale digitale deve essere campionato con frequenza  $f_s > 2f_m$  (Teorema del campionamento di Nyquist-Shannon)

#### Frequenze di campionamento audio:

- Musica: 44,1 kHz
- Voce: 8 kHz (non necessario frequenze alte)

Unità di quantizzazione solitamente codificata con 16 bit per canale

# Rappresentazione Audio



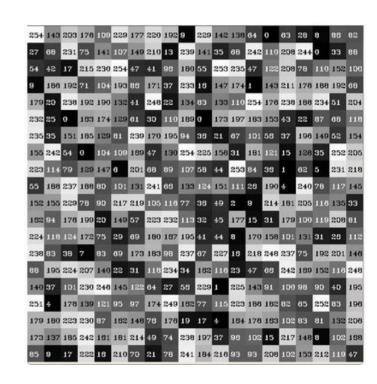
• Spazio occupato da 4 min di audio stereo:

 Codifica MIDI risparmia spazio rappresentando il suono tramite i parametri di un sintetizzatore (strumento emulato)

# Rappresentazione Immagini



- Il campionamento avviene nel domino dello spazio
- Una griglia viene applicata ad una regione limitata bidimensionale con elementi detti PIXEL
- Ogni pixel rappresenta l'intensità luminosità o di colore (grigio o RGB)
- La RISOLUZIONE rappresenta la precisione di campionamento (numero o densità dei pixel)
- La **PROFONDITÀ DI COLORE** rappresenta i livelli di quantizzazione (spesso **8 bit per canale**)



# Rappresentazione Immagini



- Immagine non compressa in formato bitmap
- Esempio di spazio occupato da un immagine a colori

Colonne X righe X canali X bit profondità = 1024 X 768 X 3 X 8 ≈ 2,25 Mbyte

 Rappresentazione vettoriale (i.e. SVG) descrive l'immagine tramite primitive geometriche (più compatta e robusta al ridimensionamento)

## Rappresentazione video



- Un video è una sequenza temporale di immagini
- 24 immagini al secondo: frequenza minima per percepire il movimento

24 X 2,25 Mbyte = 54 Mbyte / secondo

Informazione video necessita di essere compressa

## Compressione di dati



Rappresentare l'informazione con sequenze binarie più brevi perdendo poca o nessuna informazione

#### **2 FASI NELLA COMPRESSIONE:**

Codifica: c(s) = t generazione stringa compressa t da s

• Decodifica: d(t) = s ritorno alla stringa originaria s da t

#### LA COMPRESSIONE PUÒ ESSERE:

Senza perdita (lossless): d(c(s)) = s

• Con perdita (lossy):  $d(c(s)) = s + \varepsilon$ 

## RAPPORTO DI COMPRESSIONE = len(s) / len(c(s))

## Tecniche di compressione generiche



#### **RUN-LENGTH**

Codificare numero di occorrenze consecutive di ciascun simbolo

#### **DIFFERENZIALE (RELATIVA)**

 Spezzare la sequenza in blocchi, codificare il primo e codificare i successivi come differenze dal precedente

#### **VARIABLE-LENGTH**

 Lunghezza codifica dei simboli inversamente proporzionale alla probabilità di incontrarli (codici di Huffman)

#### **BASATA SU DIZIONARIO, ADATTIVA**

- I codici rappresentano parole di un dizionario
- Adattiva: il dizionario è creato dinamicamente (algoritmo LZW)

# Standard di compressione dati multimediali



#### **Audio**

- MP3: dati musicali
- OGG/VORBIS: dati musicali (più efficace ma meno usato dell'MP3)
- Speex: compressione del parlato

#### **Immagini**

- GIF: Graphical Interchange Format (Lossless)
- PNG: Portable Network Graphics (Lossless)
- JPEG: Joint Photographic Experts Group (Lossy)

#### Video

- MPEG: Motion Picture Experts Group
  - Compressione video: JPEG + codifica relativa
  - Compressione audio: MP3